




Universidad Veracruzana
Facultad de Estadística e Informática
Licenciatura en Ingeniería en Ciencia de Datos



Metodología de la Investigación

Docente:

Lorena López Lozada

Tarea 7:

Aplica CRISP

21 de septiembre de 2026

Equipo Laudatorios:

Sayuri Baltazar Pedraza

Javier Zair Galán Trujillo

Oscar Alberto Dominguez Ortega

1. Comprensión del problema

El interés inicial es estudiar los beneficios de la natación en la salud mental de estudiantes universitarios. Debido a que la base agrupa distintas actividades acuáticas, el análisis se delimita a la relación entre deportes acuáticos y bienestar mental.

Pregunta de investigación: ¿Qué diferencias existen en el bienestar mental entre estudiantes universitarios que reportan practicar deportes acuáticos y quienes no, y qué capacidad predictiva tienen las variables disponibles?

Objetivo general: Analizar esa diferencia y explorar la predicción del bienestar mental mediante un árbol de regresión que considere práctica acuática, edad, género, país y actividad física.

El estudio es cuantitativo, observacional, transversal y comparativo, con un componente predictivo exploratorio. Se utilizan datos previamente recopilados, sin asignar actividades ni realizar seguimiento temporal.

2. Comprensión de los datos

La fuente es el conjunto de datos del proyecto AUN-HPN alojado en Harvard Dataverse. El archivo ALL_aun_pacs210914(4).csv contiene 15,366 registros y 164 variables, correspondientes a estudiantes de Brunéi, Indonesia, Malasia, Filipinas, Singapur, Tailandia y Vietnam.

Para este análisis se seleccionaron las siguientes variables:

Variable	Función en el análisis
watersport	Distinguir entre estudiantes que reportan deportes acuáticos (1) y quienes no (0).
wemwbs1 a wemwbs7	Construir la puntuación de bienestar mental.
age	Incorporar la edad al modelo.
gender	Incorporar el género como variable categórica.
country	Considerar diferencias entre países.
gpaq1	Incorporar la frecuencia de actividad física, registrada de 0 a 7.

Se identificaron 5,024 estudiantes con práctica acuática (32.7%) y 10,342 sin ella (67.3%). El segundo grupo puede practicar otros deportes; no equivale a un grupo sedentario.

3. Preparación de los datos

Se realizaron las siguientes verificaciones y transformaciones:

- **Identificación y duplicados:** Los 15,366 identificadores son únicos y no existen filas completamente duplicadas.
- **Criterios de inclusión:** Contar con watersport igual a 0 o 1 y respuestas válidas, de 1 a 5, en los siete reactivos de bienestar. Todos los registros cumplieron estos criterios.

- **Variable de respuesta:** Se sumaron los siete reactivos para obtener una puntuación bruta de 7 a 35. Los valores mayores representan mayor bienestar reportado. Se utilizó como indicador exploratorio, sin establecer categorías clínicas.
- **Datos faltantes:** Se encontraron 1,769 edades ausentes (11.5 %). Para el árbol se imputaron con la mediana del conjunto de entrenamiento: 20 años.
- **Codificación:** Género y país se transformaron en variables indicadoras, evitando asignarles un orden numérico artificial.
- **Prevención de fuga de información:** La imputación y la codificación se ajustaron únicamente con los datos de entrenamiento. Los siete reactivos de bienestar quedaron excluidos de los predictores porque integran la respuesta.

No se eliminaron observaciones por presentar puntuaciones extremas válidas.

4. Modelado

Se aplicaron dos procedimientos complementarios.

Comparación de medias. Se utilizó la prueba t de Welch para contrastar la igualdad de medias entre los grupos, con un nivel de significancia de 0.05. Se calcularon la diferencia de medias, su intervalo de confianza del 95 % y el tamaño del efecto mediante d de Cohen. La comparación es sin ajuste por otras variables.

Árbol de regresión. Se ajustó un modelo para predecir la puntuación de bienestar mediante watersport, age, gender, country y gpaq1, con esta configuración:

Elemento	Configuración
Entrenamiento	80 %: 12,292 registros
Prueba	20 %: 3,074 registros
División	Estratificada por práctica acuática
Profundidad máxima	3
Mínimo de observaciones por hoja	200
Semilla aleatoria	42

Se comparó su desempeño con un modelo de referencia que predice siempre la media del conjunto de entrenamiento.

5. Evaluación

Los resultados recalculados en el archivo analizado fueron:

Grupo	Estudiantes	Media de bienestar	Desviación estándar
Sin deportes acuáticos	10,342	23.25	4.57
Con deportes acuáticos	5,024	23.93	4.60

La diferencia fue de 0.675 puntos a favor del grupo con deportes acuáticos, con IC del 95 % de 0.520 a 0.830 y $p < 0.001$. Sin embargo, el tamaño del efecto fue pequeño: $d = 0.147$. Por tanto, la significancia estadística no implica una diferencia grande o clínicamente relevante.

En los datos de prueba, el árbol obtuvo:

Indicador	Árbol de regresión	Modelo de referencia
Error absoluto medio (MAE)	3.55	3.62
Raíz del error cuadrático medio (RMSE)	4.57	4.66
R^2	0.036	≈ 0

El árbol mejoró ligeramente la predicción de referencia, pero su capacidad predictiva fue baja. Sus divisiones utilizaron actividad física, país y edad. La práctica acuática no fue seleccionada en este árbol pequeño; esto no demuestra que carezca de asociación con el bienestar.

La interpretación considera estas limitaciones:

- El diseño transversal permite identificar asociaciones, sin establecer causalidad.
- 4,938 de los 5,024 practicantes acuáticos también reportan otros deportes, lo que dificulta atribuir las diferencias específicamente a la actividad acuática.
- La comparación de medias no controla diferencias entre países, universidades u otras características.
- La imputación de edades introduce incertidumbre y el árbol solo cuenta con una evaluación interna.
- Los resultados corresponden a los estudiantes incluidos; su aplicación a universitarios mexicanos requiere evidencia adicional.

6. Despliegue y comunicación

El producto de esta fase es un informe académico que presenta la procedencia de los datos, las variables utilizadas, las decisiones de preparación, los resultados y sus limitaciones. Para permitir su reproducción, la entrega debe acompañarse del script utilizado y conservar los parámetros del modelo y la semilla aleatoria.

Conclusión del análisis: Los estudiantes que reportan deportes acuáticos presentan un bienestar mental promedio ligeramente mayor. La diferencia es pequeña y el árbol ofrece una predicción limitada. Estos resultados aportan evidencia exploratoria para continuar investigando la relación, sin demostrar beneficios causales de la natación.

Referencias

Cobos, C. (2010). *CMIN - herramienta case basada en CRISP-DM para el soporte de proyectos de minería de datos*. *Ingeniería e Investigación*, 30 (3), 45-56: (ed.). D - Ingeniería e Investigación. <https://elibro.net/es/lc/biblioteca/uv/titulos/96335>

Amonsriwatanakul, A., Chia, M., Promjun, T., & Rahman, H. A. (2025). *Dataset on physical activity, health risk factors, and mental wellbeing of university students in ASEAN (Association of South East Asian Nations) University Network – Health Promotion Network* [Conjunto de datos]. Harvard Dataverse. <https://doi.org/10.7910/DVN/EWHO00>

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Moher, D. (2021). *Declaración PRISMA 2020: una guía actualizada para la publicación de revisiones sistemáticas*. *Revista Española de Cardiología*, 74(9), 790–799. <https://doi.org/10.1016/j.recesp.2021.06.016>