




Universidad Veracruzana
Facultad de Estadística e Informática
Licenciatura en Ingeniería en Ciencia de Datos



Metodología de la Investigación

Docente:

Lorena López Lozada

Tarea 7:

Aplica SEMMA

26 de septiembre de 2026

Equipo Laudatorios:

Sayuri Baltazar Pedraza

Javier Zair Galán Trujillo

Oscar Alberto Dominguez Ortega

SEMMA aplicada a los deportes acuáticos y el bienestar mental

Introducción

SEMMA es un proceso de minería de datos desarrollado por SAS que comprende cinco etapas: seleccionar datos, explorar, modificar, modelar y evaluar. En esta investigación permite organizar el análisis de la relación entre deportes acuáticos y bienestar mental en estudiantes universitarios. La tarea retoma los datos y resultados del análisis previo: prepara las variables, compara los grupos y evalúa un árbol de regresión. Se encuentra un bienestar promedio ligeramente mayor entre practicantes acuáticos y una capacidad predictiva limitada del modelo. El alcance se restringe a deportes acuáticos porque la base no identifica exclusivamente la natación.

1. Sample - Selección y partición de los datos

Se utiliza la base del proyecto AUN-HPN, alojada en Harvard Dataverse, con 15,366 estudiantes. Los criterios de inclusión son contar con una respuesta válida sobre práctica acuática y valores de 1 a 5 en los siete reactivos de bienestar. Todos los registros cumplen estos criterios y no existen identificadores duplicados.

Se conservan los grupos con y sin práctica acuática para compararlos. Para el árbol se asigna el 80 % al entrenamiento (12,292 registros) y el 20 % a prueba (3,074), mediante una división estratificada por práctica acuática y semilla 42.

2. Explore - Exploración de los datos

Se examinan distribuciones, datos faltantes y diferencias entre grupos mediante estadísticas descriptivas y diagramas de caja. El resumen del bienestar es el siguiente:

Práctica acuática	Estudiantes	Media	Desviación estándar
Sin práctica acuática	10,342	23.25	4.57
Con práctica acuática	5,024	23.93	4.60

Las distribuciones se superponen ampliamente. Se detectan 1,769 edades faltantes (11.5 %). El grupo sin práctica acuática puede realizar otros deportes, por lo que no equivale a un grupo sedentario.

3 Modify - Preparación de los datos

Se suman los siete reactivos para obtener una puntuación bruta de bienestar de 7 a 35, utilizada como indicador exploratorio, sin categorías clínicas. Para el árbol, las edades faltantes se sustituyen por la mediana del entrenamiento, de 20 años, y género y país se codifican mediante variables indicadoras.

La imputación y la codificación se ajustan solo con el entrenamiento y después se aplican a prueba. Los siete reactivos se excluyen de los predictores porque integran la respuesta, evitando fuga de información. Se conservan las puntuaciones extremas válidas.

4 Model - Modelado

Es un modelo que divide a los estudiantes según sus características para predecir su puntaje de bienestar. En cada nodo, 'samples' indica el número de estudiantes y 'value', su bienestar promedio.




Imagen 2. Árbol de regresión

Se ajusta un árbol de regresión para predecir la puntuación de bienestar a partir de práctica acuática, edad, género, país y frecuencia de actividad física. Se fija una profundidad máxima de 3, un mínimo de 200 observaciones por hoja y semilla 42. El entrenamiento utiliza únicamente el 80 % de los registros asignado a esta fase.

Como análisis estadístico complementario, se aplica la prueba t de Welch para comparar las medias, con significancia de 0.05, intervalo de confianza del 95 % y tamaño del efecto mediante d de Cohen. Esta comparación no se ajusta por otras variables.

5 Assess - Evaluación

La diferencia de medias es de 0.675 puntos a favor de quienes practican deportes acuáticos, con intervalo de confianza del 95 % de 0.520 a 0.830 y $p < 0.001$. El tamaño del efecto es pequeño ($d = 0.147$); la significancia estadística no implica una diferencia grande o clínicamente relevante.

El árbol se evalúa con los registros de prueba y se compara con un modelo de referencia que predice siempre la media del entrenamiento:

Indicador	Árbol de regresión	Modelo de referencia
Error absoluto medio (MAE)	3.55	3.62
Raíz del error cuadrático medio (RMSE)	4.57	4.66
Coefficiente de determinación (R^2)	0.036	≈ 0

La mejora predictiva es reducida. Las divisiones del árbol utilizan actividad física, país y edad. La práctica acuática no se selecciona en este modelo pequeño; esto no demuestra ausencia de asociación con el bienestar.

La evaluación considera que el estudio es transversal y que 4,938 de los 5,024 practicantes acuáticos también realizan otros deportes. Estas condiciones impiden atribuir la diferencia específicamente a la actividad acuática o establecer causalidad. Los resultados corresponden a los estudiantes incluidos en la base.

Hallazgos y utilidad para la investigación

El análisis permitió conocer que la práctica acuática se asocia con un bienestar promedio ligeramente mayor, pero que la magnitud de esa diferencia es pequeña. También mostró que las variables disponibles, utilizadas en un árbol sencillo, tienen capacidad limitada para predecir el bienestar individual.

Estos hallazgos ayudan a delimitar el tema hacia deportes acuáticos y a formular conclusiones proporcionales a la evidencia. SEMMA permitió ordenar el trabajo, documentar la preparación y evaluar si el modelo aportaba una mejora real. Para continuar la investigación, sería útil distinguir la natación de otros deportes y contar con seguimiento temporal. Los hallazgos proceden del análisis previo de la base; esta tarea los organiza e interpreta mediante SEMMA.

Referencias

Maldonado, S. (2022). *Analytics y Big Data: ciencia de los Datos aplicada al mundo de los negocios*: (1 ed.). RIL editores. <https://elibro.net/es/lc/bibliotecauv/titulos/225562>

Amonsriwatanakul, A., Chia, M., Promjun, T., & Rahman, H. A. (2025). *Dataset on physical activity, health risk factors, and mental wellbeing of university students in ASEAN (Association of South East Asian Nations) University Network – Health Promotion Network* [Conjunto de datos]. Harvard Dataverse. <https://doi.org/10.7910/DVN/EWHO00>

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Moher, D. (2021). *Declaración PRISMA 2020: una guía actualizada para la publicación de revisiones sistemáticas*. *Revista Española de Cardiología*, 74(9), 790–799. <https://doi.org/10.1016/j.recesp.2021.06.016>